



## Data Normalization

- scop: de a transforma / ajusta date pt a fi la o scară similară
- utilizat în performanță pt ML (machine learning)

### Metode de normalizare

- clipping (tăiere)
  - log scaling (scalare jurnal)
  - scalare min-max
  - standardizare
- mean = medie
  - stddev = deviația standard de la media unor date
  - outlier = o val. f. diferită de celelalte din setul de date (poate afecta rezultatul)
    - ↳ efect semnificativ asupra mediei și a abaterii standard

### CLIPPING

= limitarea datelor care limitează toate valorile carct. de deasupra / de dedesubt unei anumite valori la o val. fixă

$$x_i^{\text{new}} = \begin{cases} x_i, & x_i < \text{val fixă} \\ \text{val fixă}, & x_i \geq \text{val fixă} \end{cases}$$

- se utilizează când există outliers extreme

## Obiecte - clasificare și detecție

### Regresia

- var. țintă este continuă →  
→ predicția este o val. numerică
- ex: estimare temperatură,  
prețuri veneturi
- calitate predicție:
  - însumarea dif. (ridicată la pătrat)  
dintre val. reală și cea prezisă de alg.

### Clasificarea

- var. țintă este discretă →  
→ predicția este o clasă / categorie
- ex: clasificare emailuri,  
detectare tip obiect din img.
- calitate predicție:  
nr. dif. dintre val. reală  
și val. prezisă

## Algoritmul gradient descent

- problemele de regresie

- identifi relația de dependență dintre date independente și date dependente

poate fi:

- liniară
- ne-liniară

Pas pt a identifica relația de dependență:

- colectarea datelor
- explorarea datelor (plot)
- selectare model regresie (ex: liniară, polinomială, ...)
- antrenare model
- evaluare model (performanță → metrici de evaluare)
- interpretare rezultate

- pe baza unor caract. a datelor se deduce prezența unor valori asociate cu aceste date

- valorile prezise sunt de tip continuu

↳ var. dependentă poate lua o gamă largă de valori dintr-un interval continuu.

↳ „nu conțin găuri”

- datele se caracterizează prin atribute și output

$$X = (x_1, x_2, \dots, x_n)$$

- regresorul  
(model liniar  
de predicție)


$$y = f(x, w) = w_0 + w_1 \cdot x_1 + w_2 \cdot x_2 + \dots$$

# Metodologia rezolvării unei probleme de regresie linieară

## • Antrenare

### Algorithm

- least Square
- Gradient Descent



### Output

- model regresie  
(adică  $w$ )

$$f(x, w) = w_0 + w_1 x_1 + \dots$$

## • Testare

### Algorithm

- regresorul învățat  
pt val. output

$$y_{\text{new}} = f(x_{\text{new}}, w)$$

### Input

- exemplu ne-etichetat  
 $x_{\text{new}} \rightarrow$  vector de  
atribute

### Output

- val. predică pt  
 $x_{\text{new}}$

## Metoda de gradient descendent